

Tarea #2: Análisis de sentimiento en Reseñas de Yelp

1. Introducción y Objetivos

El procesamiento de texto mediante modelos computacionales requiere transformar caracteres alfanuméricos en representaciones numéricas que los algoritmos puedan procesar. Esta tarea evalúa y contrasta el enfoque estadístico de **Bolsa de Palabras (Bag of Words)** y el enfoque semántico basado en aprendizaje profundo mediante el **Fine-Tuning de BERT** (*Bidirectional Encoder Representations from Transformers*).

El objetivo principal es analizar las propiedades vectoriales de ambos métodos y evaluar la capacidad predictiva de BERT al clasificar el sentimiento de reseñas de usuarios provenientes de la plataforma Yelp, contrastando de manera matemática las predicciones del modelo con la calificación numérica real (escala de 1 a 5 estrellas) otorgada por los consumidores.

2. Metodología y Preprocesamiento

Para el desarrollo experimental se utilizó un subconjunto de datos balanceado del dataset de Yelp, el cual consiste en 2,500 registros (2,000 para la fase de entrenamiento y 500 muestras independientes para la validación y prueba).

Debido a la naturaleza arquitectónica de cada método de vectorización, se implementaron dos flujos de preprocesamiento opuestos:

- **Flujo Estadístico (Bolsa de Palabras):** Se estandarizó el texto a minúsculas, se removieron signos de puntuación y caracteres especiales, y se eliminaron las palabras vacías (*stopwords*) del idioma inglés.
- **Flujo Semántico (BERT):** A diferencia del método clásico, BERT requiere preservar la estructura sintáctica, los conectores, los modificadores de sentido (como las negaciones "not", "no") y el orden original del texto. Por ello, no se eliminaron *stopwords* ni se realizó lematización. El texto en crudo se procesó mediante el tokenizador oficial bert-base-uncased, utilizando el algoritmo *WordPiece* para fragmentar términos desconocidos en subpalabras y aplicando técnicas de truncado y relleno (*padding*) a una longitud fija de 128 tokens.

3. Estudio de las Propiedades de los Vectores

3.1. Enfoque Estadístico: Bolsa de Palabras (BoW)

Al aplicar el modelo de conteo clásico sobre la submuestra de prueba, se obtuvo una matriz con una forma dimensional de 500 X 1000, donde 500 corresponde a la cantidad de documentos analizados y 1,000 al tamaño asignado al vocabulario.

Al evaluar las propiedades de esta representación, el análisis matemático arrojó una **Propiedad de Escasez (*Sparsity*) del 96.68%**. Esto significa que casi la totalidad de la matriz de datos está compuesta por ceros. Esta alta dispersión es una propiedad inherente de los modelos vectoriales analíticos no contextuales; el modelo gasta recursos de memoria almacenando posiciones vacías

debido a que una reseña individual solo utiliza una fracción minúscula del vocabulario global disponible, omitiendo por completo la semántica, el contexto y la posición de las palabras.

3.2. Enfoque Semántico: Embeddings de BERT

La arquitectura de BERT genera vectores continuos y densos. En lugar de mapear frecuencias de palabras aisladas, cada token y documento se proyecta en un espacio vectorial continuo de 768 dimensiones fijas.


La propiedad fundamental de estos vectores es la densidad semántica (0% de escasez funcional) y la contextualización por medio del mecanismo de atención bidireccional. Palabras idénticas adquieren representaciones vectoriales distintas dependiendo de los términos que las rodean.

4. Resultados y Discusión

Tras realizar el ajuste fino del modelo clasificador secuencial de BERT a lo largo de 2 épocas de entrenamiento, se obtuvieron las siguientes métricas de rendimiento sobre el conjunto de prueba:

Clase (Calificación)	Precisión (Precision)	Sensibilidad (Recall)	Puntuación F1 (F1-Score)	Soporte (Support)
1 Estrella	0.61	0.76	0.68	110
2 Estrellas	0.47	0.35	0.40	112
3 Estrellas	0.52	0.50	0.51	92
4 Estrellas	0.49	0.50	0.49	100
5 Estrellas	0.61	0.63	0.62	86
Exactitud (Accuracy)			0.55	500
Macro Average	0.54	0.55	0.54	500
Weighted Average	0.54	0.55	0.54	500

4.1. Interpretación de la Matriz de Confusión



El análisis visual del mapa de calor de la Matriz de Confusión permite llegar a las siguientes conclusiones:

1. El modelo demuestra su mejor desempeño en las clasificaciones de los extremos (1 ó 5). Logró identificar correctamente 84 de 110 reseñas de 1 estrella (Sensibilidad del 76%) y 54 de 86 reseñas de 5 estrellas (Sensibilidad del 63%). Lingüísticamente, esto se justifica porque las reseñas muy negativas o muy positivas contienen un vocabulario explícito y contundente de insatisfacción.
2. El mapa de calor revela una fuerte concentración de errores en los bloques alrededor a la diagonal principal. Por ejemplo, de las 112 reseñas reales de 2 estrellas, el modelo clasificó erróneamente 43 como 1 estrella y 23 como 3 estrellas. De igual forma, las reseñas de 4 estrellas suelen confundirse con las de 5 (29 casos). La diferencia escrita entre calificar un servicio con 4 o 5 estrellas, o con 1 o 2 estrellas, suele ser altamente subjetiva e incluso difusa para un evaluador humano, ya que comparten estructuras de texto muy similares.
3. El modelo casi nunca comete errores de polaridad inversa; por ejemplo, de las reseñas reales de 1 estrella, 0 fueron clasificadas como 5 estrellas, y de las de 5 estrellas, solo 2 se clasificaron como 1 estrella. Esto confirma que BERT entiende la dirección del sentimiento general.

5. Conclusiones

El desarrollo de esta práctica permitió comprobar que las representaciones vectoriales densas basadas en arquitecturas de Transformers superan a los métodos estadísticos de conteo de palabras. Mientras que la Bolsa de Palabras sufre del problema de escasez dimensional (96.68% de ceros) y pérdida de contexto, BERT capta relaciones sintácticas profundas.

La evaluación frente a las calificaciones numéricas reales de Yelp demostró que un *Accuracy* del 55% representa un modelado decente para un problema de clasificación complejo de 5 clases discretas. Los errores detectados no corresponden a fallas del algoritmo, sino a la manera en que los comensales/clientes llegan a expresar sus opiniones en las reseñas.